

RPM4 2025: correction du TD statistique

Clément Gauchy

Novembre 2025

Exercice 1

- 1) Le modèle statistique de ce problème est $\mathcal{M} = \{\mathcal{P}(\lambda), \lambda > 0\}$. On doit estimer le paramètre d'intensité λ de la source d'émission de particule.
- 2) On possède un échantillon i.i.d. $\mathcal{D} = (N_i)_{1 \leq i \leq k}$, la vraisemblance s'écrit alors comme

$$\mathcal{L}(\lambda; \mathcal{D}) = \mathbb{P}(N_1, \dots, N_k) \quad (1)$$

$$= \prod_{i=1}^k \mathbb{P}(N_i) \quad (2)$$

$$= \prod_{i=1}^k e^{-\lambda} \frac{\lambda^{N_i}}{N_i!} \quad (3)$$

La log vraisemblance s'écrit alors

$$\ell(\lambda; \mathcal{D}) = \sum_{i=1}^k -\lambda + N_i \log(\lambda) - \log(N_i!)$$

L'estimateur du maximum de vraisemblance est défini comme le maximum de $\ell(\lambda; \mathcal{D})$. On a alors

$$\frac{\partial \ell}{\partial \lambda}(\hat{\lambda}^{\text{EMV}}; \mathcal{D}) = 0 \quad (4)$$

$$\sum_{i=1}^k -1 + \frac{N_i}{\hat{\lambda}^{\text{EMV}}} = 0 \quad (5)$$

$$\hat{\lambda}^{\text{EMV}} = \frac{\sum_{i=1}^k N_i}{k} \quad (6)$$

□

- 3) On construit un premier estimateur des moments $\hat{\lambda}_{M1}$ à l'aide du premier moment de la loi de Poisson:

$$\mathbb{E}[N_1] = \lambda. \quad (7)$$

On remplace le membre de gauche par son approximation empirique:

$$\mathbb{E}[N_1] \approx \frac{1}{k} \sum_{i=1}^k N_i.$$

Cette approximation permet de définir l'estimateur $\hat{\lambda}_{M1}$, il suffit de le rajouter dans le membre de gauche de l'équation (7) :

$$\hat{\lambda}_{M1} :=^1 \frac{1}{k} \sum_{i=1}^k N_i .$$

On remarque que $\hat{\lambda}_{M1} = \hat{\lambda}_{EMV}$. On recherche désormais à construire un nouvel estimateur des moment à l'aide du moment d'ordre deux:

$$\mathbb{E}[N_1^2] = \lambda^2 + \lambda . \quad (8)$$

De la même façon que pour $\hat{\lambda}_{M1}$, on définit $\hat{\lambda}_{M2}$ par l'équation suivante:

$$\hat{\lambda}_{M2}^2 + \hat{\lambda}_{M2} := \frac{1}{k} \sum_{i=1}^k N_i^2 .$$

Pour déterminer la valeur de $\hat{\lambda}_{M2}$, on doit résoudre l'équation du second degré suivante:

$$x^2 + x - \bar{N}^2 = 0 .$$

avec $\bar{N}^2 = \frac{1}{k} \sum_{i=1}^k N_i^2$. Le discriminant est $\Delta = 1 + 4\bar{N}^2 > 0$, l'équation admet donc deux solutions réelles:

$$x_1 = \frac{-1 - \sqrt{4\bar{N}^2 + 1}}{2} \quad (9)$$

$$x_2 = \frac{-1 + \sqrt{4\bar{N}^2 + 1}}{2} \quad (10)$$

La solution x_1 est non valide car $x_1 < 0$ pour toutes valeurs de $\bar{N}^2$, la solution x_2 est valide car elle est toujours positive pour $\bar{N}^2$ positif. Ainsi

$$\hat{\lambda}_{M2} = \frac{-1 + \sqrt{4\bar{N}^2 + 1}}{2} .$$

L'estimateur $\hat{\lambda}_{M2}$ est probablement biaisé (verification numérique).

3) On applique la règle de Bayes pour calculer la loi *a posteriori*

$$p(\lambda|\mathcal{D}) = \frac{\mathcal{L}(\lambda; \mathcal{D})p(\lambda)}{p(\mathcal{D})}$$

On va calculer la loi *a posteriori* à une constante prêt

$$p(\lambda|\mathcal{D}) \propto \mathcal{L}(\lambda; \mathcal{D})f_{\alpha,\beta}(\lambda) \quad (11)$$

$$p(\lambda|\mathcal{D}) = \prod_{i=1}^k e^{-\lambda} \frac{\lambda^{N_i}}{N_i!} \lambda^{\alpha-1} e^{-\beta\lambda} \quad (12)$$

$$p(\lambda|\mathcal{D}) = e^{-k\lambda} \lambda^{\sum_{i=1}^k N_i} \lambda^{\alpha-1} e^{-\beta\lambda} \quad (13)$$

$$p(\lambda|\mathcal{D}) = \lambda^{\alpha-1 + \sum_{i=1}^k N_i} e^{-(k+\beta)\lambda} \quad (14)$$

On remarque que $p(\lambda|\mathcal{D})$ est une loi Gamma de paramètre $\alpha + \sum_{i=1}^k N_i$ et $k + \beta$.

¹l'équation $x := y$ signifie que x est défini par la quantité y

4) La moyenne d'une loi $\Gamma(\alpha, \beta)$ est $\frac{\alpha}{\beta}$ ainsi l'estimateur de la moyenne *a posteriori* est

$$\frac{\alpha + \sum_{i=1}^k N_i}{\beta + k}$$

Le mode de la loi gamma $\Gamma(\alpha, \beta)$ est $\frac{\alpha-1}{\beta}$ d'où l'estimateur MAP

$$\frac{\alpha - 1 + \sum_{i=1}^k N_i}{\beta + k}$$

Exercice 3

- 1) X suit une loi exponentielle de paramètre μ , $X \sim \mathcal{E}(\mu)$.
- 2) p représente la proportion de particules qui transervent le matériau sans interaction avec celui ci. Cette quantité est importante car elle représente le rayonnement que l'opérateur recevra. Si le rayonnement est ionisant, cela peut avoir des conséquences de santé sur l'opérateur.
- 3) On utilise la propriété $\mathbb{P}(X > L) = \mathbb{E}[\mathbf{1}_{X>L}]$. On peut écrire l'estimateur Monte-Carlo à l'aide de la loi des grands nombres.

$$\hat{p}_{MC} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{X_i > L}$$

- 4) On a $\mathbb{E}[\hat{p}_{MC}] = p$ et $\text{Var}(\hat{p}_{MC}) = \frac{p(1-p)}{N}$ ainsi

$$cv = \frac{\sqrt{p(1-p)}}{p\sqrt{N}}.$$

Vu que $p = 10^{-6}$ on peut faire l'approximation $1 - p \approx 1$ et ainsi

$$cv \approx \frac{1}{\sqrt{Np}}$$

Si on souhaite $cv \approx 1\% = 10^{-3}$ alors $N = 10^{12}$. On remarque que c'est un nombre de simulations aléatoires très important, on peut attendre les limites des moyens de calcul. De plus, dans un modèle plus réaliste (exemple: matériau non homogène) chaque simulation d'une trajectoire de particule peut être couteuse en temps de calcul, l'estimateur Monte-Carlo va donc être très compliqué à calculer.

- 5) On utilise pour cela le théorème de Bayes:

$$\mathbb{P}(X > L) = \mathbb{P}(X > L | X > A) \mathbb{P}(X > A).$$

- 6) On peut caractériser la loi de probabilité de Y via sa fonction de répartition $\mathbb{P}(Y < T)$, pour tout $T > 0$. D'après l'énoncé on a

$$\mathbb{P}(Y < T) = \frac{\mathbb{P}(A < X < T)}{\mathbb{P}(X > A)}.$$

Or, on sait que X suit une loi exponentielle, ayant pour densité $f(t) = \lambda e^{-\lambda t}$, d'où:

$$\mathbb{P}(Y < T) = \frac{\int_A^T \lambda e^{-\lambda t} dt}{\int_A^{+\infty} \lambda e^{-\lambda t} dt}$$

$$\mathbb{P}(Y < T) = \frac{e^{-\lambda A} - e^{-\lambda T}}{e^{-\lambda A}} = 1 - e^{-\lambda(T-A)}$$

La loi de Y est donc la loi de la variable aléatoire $A + X$.

7) On a d'après la question 5) que

$$\mathbb{P}(X > L) = \mathbb{P}(X > A)\mathbb{P}(Y > L).$$

On peut remplacer le produit des probabilités par leur estimations empirique permettant de définir $\hat{p}_S$:

$$\hat{p}_S := \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{X_i > A} \times \frac{1}{N} \sum_{i=1}^N \mathbf{1}_{Y_i > L}$$

L'estimateur est sans biais (car les X_i et Y_i sont mutuellement indépendants) [SUITE DE LA CORRECTION Á VENIR]

Exercice 3

1) Le modèle statistique est $\mathcal{M} = \{f_\lambda(t) = \lambda e^{-\lambda t}, \lambda > 0\}$, le paramètre à estimer est λ .

2) D'après la loi des grands nombres, on sait que

$$\frac{1}{n} \sum_{i=1}^n T_i \rightarrow \mathbb{E}[T_1] = \frac{1}{\lambda},$$

ainsi on peut poser l'estimateur des moments suivant pour λ :

$$\frac{1}{\hat{\lambda}_n} = \frac{1}{n} \sum_{i=1}^n T_i \iff \hat{\lambda}_n = \frac{n}{\sum_{i=1}^n T_i}$$

3) On a par définition

$$\mathcal{L}(\lambda; T_1, \dots, T_n) = \prod_{i=1}^n f_\lambda(T_i)$$

$$\mathcal{L}(\lambda; T_1, \dots, T_n) = \lambda^n e^{-\lambda \sum_{i=1}^n T_i}$$

La log vraisemblance s'écrit alors

$$\ell(\lambda; T_1, \dots, T_n) = n \log(\lambda) - \lambda \sum_{i=1}^n T_i$$

le maximum de vraisemblance $\hat{\lambda}_{MV}$ annule la dérivée de la log vraisemblance:

$$\frac{\partial \ell(\hat{\lambda}_{MV}; T_1, \dots, T_n)}{\partial \lambda} = 0 \iff \frac{n}{\hat{\lambda}_{MV}} - \sum_{i=1}^n T_i = 0$$

Ainsi,

$$\hat{\lambda}_{\text{MV}} = \frac{n}{\sum_{i=1}^n T_i}$$

L'estimateur du maximum de vraisemblance est donc le même que celui des moments.

4) On écrit l'espérance $\mathbb{E} \left[\frac{1}{\sum_{i=1}^n T_i} \right]$ à l'aide du théorème de transport

$$\begin{aligned} \mathbb{E} \left[\frac{1}{\sum_{i=1}^n T_i} \right] &= \int_{\mathbb{R}^+} \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} \times \frac{1}{t} dt \\ \mathbb{E} \left[\frac{1}{\sum_{i=1}^n T_i} \right] &= \int_{\mathbb{R}^+} \frac{\lambda^n t^{n-2}}{\Gamma(n)} e^{-\lambda t} dt \\ \mathbb{E} \left[\frac{1}{\sum_{i=1}^n T_i} \right] &= \frac{\lambda}{n-1} \underbrace{\int_{\mathbb{R}^+} \frac{\lambda^{n-1} t^{n-2} e^{-\lambda t}}{\Gamma(n-1)} dt}_{= 1 \text{ car c'est la densité de probabilité de la loi } \mathcal{G}(n-1, \lambda)} \end{aligned}$$

On peut désormais calculer le biais

$$\mathbb{E}[\hat{\lambda}_{\text{MV}}] = n \mathbb{E} \left[\frac{1}{\sum_{i=1}^n T_i} \right] = \frac{n}{n-1} \lambda$$

L'estimateur du maximum de vraisemblance est donc biaisé mais asymptotiquement sans biais.

6) On applique la règle de Bayes:

$$\begin{aligned} \pi(\lambda | T_1, \dots, T_n) &\propto \mathcal{L}(\lambda; T_1, \dots, T_n) \pi(\lambda) \\ \pi(\lambda | T_1, \dots, T_n) &\propto \lambda^n e^{-\lambda \sum_{i=1}^n T_i} \lambda^\alpha e^{-\beta \lambda} \\ \pi(\lambda | T_1, \dots, T_n) &\propto \lambda^{n+\alpha} e^{-\lambda(\beta + \sum_{i=1}^n T_i)} \end{aligned}$$

On reconnaît la loi $\mathcal{G}(n + \alpha, \beta + \sum_{i=1}^n T_i)$, qui est donc la loi *a posteriori* pour ce modèle.

7) D'après les informations de l'énoncé, on a l'estimateur de la moyenne *a posteriori* $\hat{\lambda}_{\text{moy}}$ qui est égale à

$$\hat{\lambda}_{\text{moy}} = \frac{\alpha + n}{\beta + \sum_{i=1}^n T_i}.$$

L'estimateur du maximum *a posteriori* $\hat{\lambda}_{\text{MAP}}$ s'écrit quant à lui

$$\hat{\lambda}_{\text{MAP}} = \frac{\alpha + n - 1}{\beta + \sum_{i=1}^n T_i}.$$